Neuralne mreže – Projektni zadatak

Jovana Čeganjac, 2022/0423

Milica Eva Stojanović 2022/0361

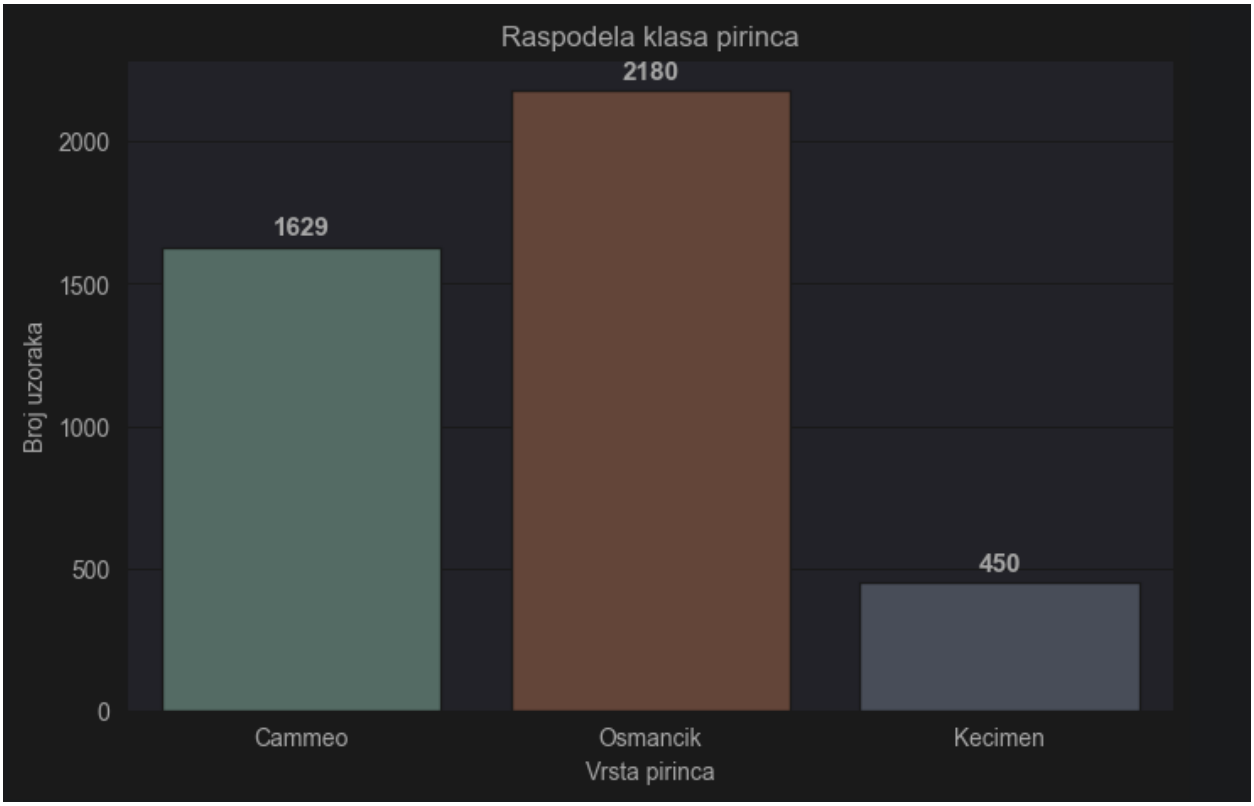
Elektrotehnički fakultet, Univerzitet u Beogradu

1. Projektovanje potpuno povezane neuralne mreže

U ovom zadatku cilj je klasifikacija vrsta pirinča na osnovu fizičkih karakteristika svakog zrna. Korišćen je skup podataka Rice.csv, koji sadrži tri klase pirinča: Cammeo, Osmancik i Kecimen.

Svako zrno opisano je sledećim numeričkim osobinama: površina (AREA), obim (PERIMETER), duža osa elipse koja aproksimira zrno (MAJORAXIS), kraća osa elipse (MINORAXIS), ekscentricitet kao mera izduženosti (ECCENTRICITY), površina konveksnog omotača (CONVEX_AREA) i udeo popunjenosti okvira (EXTENT).

Ovi atributi pružaju dobru osnovu za klasifikaciju jer zajedno opisuju veličinu, oblik i kompaktnost zrna - parametre koji prirodno prave razliku među vrstama pirinča.



Na slici je prikazana raspodela broja uzoraka po klasama. Primećujemo da su klase *Osmancik* (2180 uzoraka) i *Cammeo* (1629 uzoraka) dominantne, dok klasa *Kecimen* (450 uzoraka) ima znatno manji broj primera. Zbog uočene neuravnoteženosti klasa, tokom obuke mreže primenjeni su *class weights*. Na taj način, uzorci iz manjinskih klasa (*Kecimen*) dobijaju veću važnost, što pomaže modelu da bolje prepoznaje retke klase i povećava ukupnu osetljivost.

Nakon učitavanja podataka, prvi korak bio je razdvajanje ulaznih promenljivih (X) koje sadrže numeričke osobine zrna pirinča (površina, ekscentricitet...) od ciljne promenjive (Y), koja predstavlja klasu - vrstu pirinča .Ciljna promenjiva je zatim obrađena u dva koraka kako bi bila pogodna za upotrebu u mreži sa *Softmax* izlaznim slojem.

Najpre je primenjen *LabelEncoder* da bi se tekstualne oznake klasa pretvorile u celobrojne vrednosti. Nakon toga, izvršena je konverzija *u one-hot* reprezentaciju korišćenjem funkcije *to_categorical*. Ovaj postupak je ključan za višeklasnu klasifikaciju jer omogućava mreži da, u kombinaciji sa *categorical_crossentropy* funkcijom greške, nauči i predvidi verovatnoće za svaku klasu nezavisno, čime se obezbeđuje preciznije modelovanje izlaznih verovatnoća.

Jedan od najvažnijih koraka u pripremi numeričkih ulaznih podataka bilo je rešavanje problema različitih skala atributa. S obzirom na to da atributi kao što su površina i ekscentricitet imaju potpuno različite domene vrednosti, neobrađeni podaci bi doveli do dominacije onih sa većim skalama tokom treniranja. Da bi se ovo sprečilo, svi ulazni podaci su standardizovani pomoću *StandardScaler* metodologije. Standardizacija osigurava da svaka ulazna kolona ima nultu sredinu i jedinicu varijanse, čime se sprečava da bilo koji atribut dominira procesom učenja.

Nakon obrade, skup podataka je podeljen na tri dela sa striktnim proporcijama: 64% za trening, 16% za validaciju i 20% za testiranje. Za sve podele korišćena je opcija *stratify*. Ova opcija je neophodna jer osigurava da odnos klasa ostane proporcionalan u svim podskupovima, sprečavajući da ređe klase budu neadekvatno zastupljene (ili potpuno izostavljene) iz validacionog ili test skupa, što bi dovelo do loših procena performansi.

Pošto je histogramom utvrđena neravnomerna zastupljenost klasa, izračunate su težine klasa pomoću funkcije *compute_class_weight("balanced", ...)*. Ove težine su prosleđene argumentu *class_weight* tokom treniranja modela. Ova tehnika služi kao eksplicitan signal modelu da greške na ređim klasama treba više da "koštaju", čime se značajno poboljšava uravnoteženost performansi po klasama i sprečava da model favorizuje dominantnu klasu. Svi ovi koraci su optimalno pripremili podatke za treniranje mreže.

Korišćen je jednostavan sekvencijalni model - *Sequential* sa tri potpuno povezana sloja.

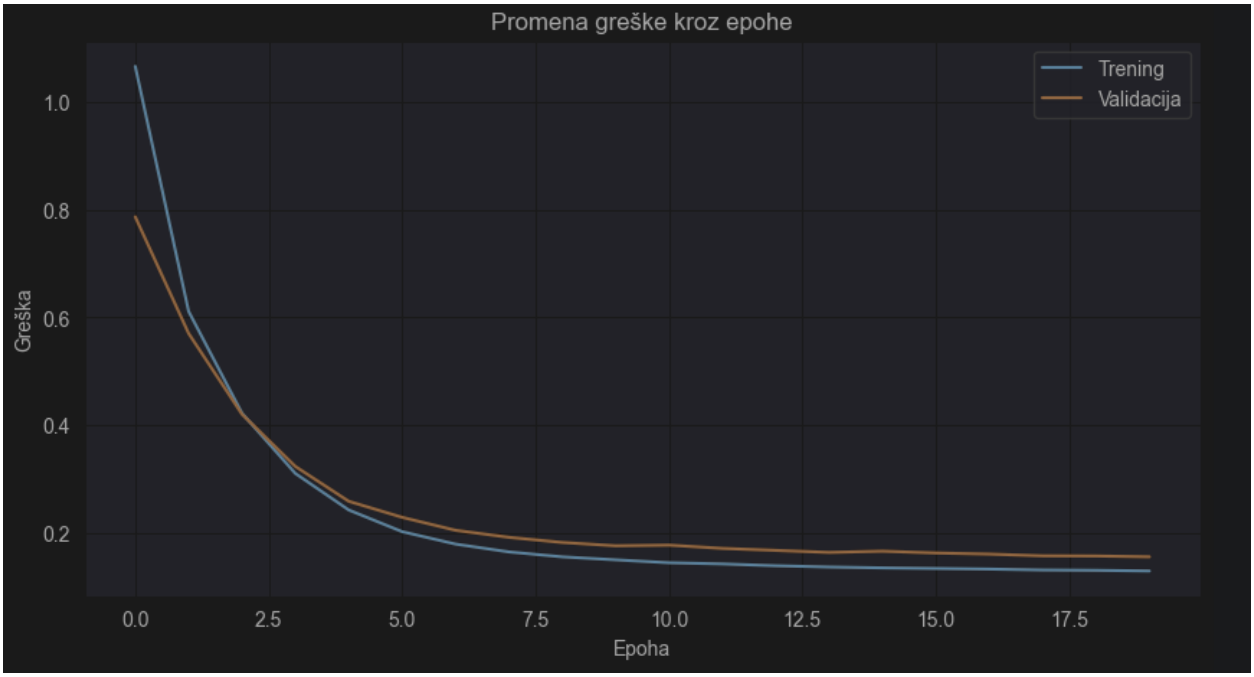
Arhitektura modela:

```
model = Sequential([
    Dense(32, activation="relu", input_shape=(x_trening.shape[1],)),
    Dense(16, activation="relu"),
    Dense(y_kategoricki.shape[1], activation="softmax")
])
```

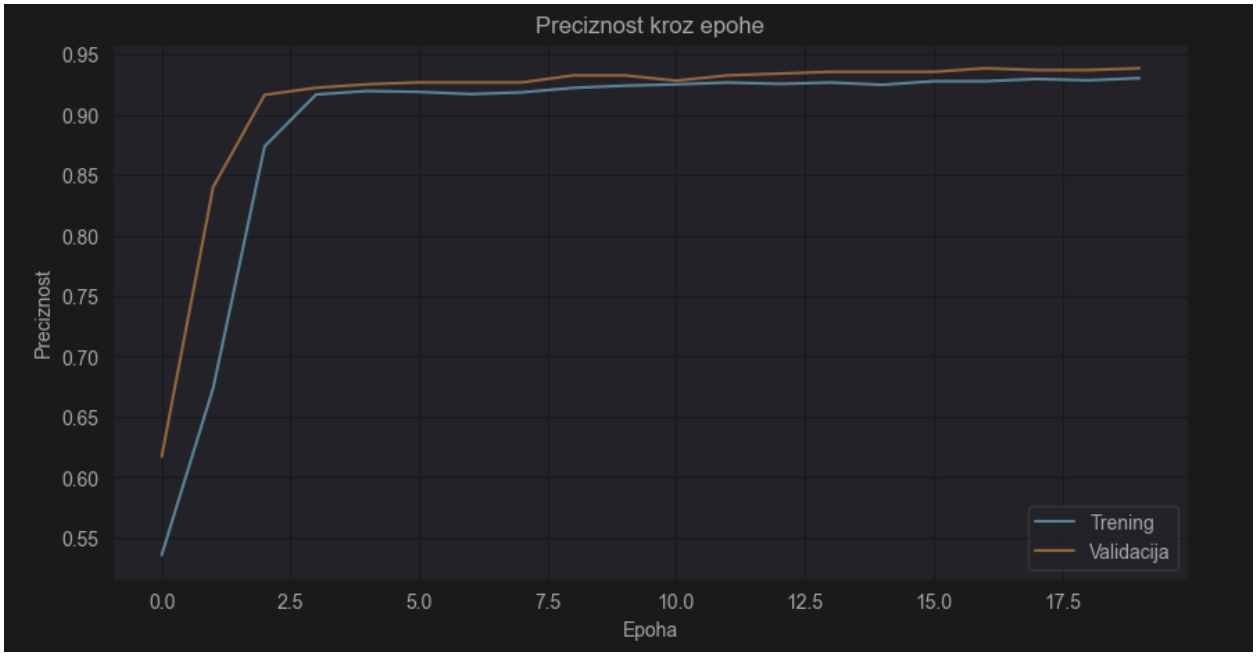
Čine je dva skrivena sloja sa 32 i 16 neurona, pri čemu je za oba sloja odabrana *ReLU* aktivaciona funkcija radi brže i efikasnije obuke, bez rizika od nestajanja gradijenata. Izlazni sloj koristi *Softmax* kako bi se izlazi pretvorili u distribuciju verovatnoća po klasama, što je neophodno za korišćenje funkcije greške *categorical_crossentropy*. Korišćen je optimizator Adam i on omogućava stabilno i brzo treniranje, a stopa učenja mu je postavljena na 0.0004.

Kao glavna mera protiv prenaučenosti (*overfitting*) korišćena je tehnika *Early Stopping*. Ova tehnika prati kako model radi na validacionom skupu (koji nikada pre nije video) i automatski prekida obuku ako ne dođe do poboljšanja performansi tokom četiri uzastopne epohe. Time se osigurava da se model zaustavi u optimalnoj tački, tako da sistem vrati najbolje rezultate koje je model postigao.

Model je treniran u 20 epoha, sa veličinom *batch-a* 32. Tokom obuke, posmatrane su krive gubitka i tačnosti za trening i validacioni skup.



Sa slike se vidi da funkcija greške naglo opada tokom prvih nekoliko epoha, što ukazuje da model brzo uči osnovne obrasce u podacima. Nakon desetak epoha greška se stabilizuje; validaciona greška tokom celog procesa ostaje približna trening grešci, što znači da ne dolazi do *Overfitting-a,* kao i da model zadržava dobru sposobnost generalizacije – pouzdano predviđa na podacima koje ranije nije video.



Krive preciznosti pokazuju brz porast tačnosti u prvim epohama, nakon čega obe krive (trening i validacija) prelaze 90% i gotovo se izjednačavaju. Ovakav obrazac potvrđuje da je obuka uspešna i stabilna, bez divergencije ili oscilacija koje bi ukazivale na preveliku stopu učenja.

Nakon treniranja, model je testiran na potpuno nezavisnom skupu podataka.

Dobijena je ukupna tačnost od 0.93, što ukazuje da mreža ispravno klasifikuje 93% uzoraka koje nije videla tokom učenja.

```
Ukupna tačnost: 0.93

Performanse po klasama:

          Preciznost  Osetljivost  F1-skor
Cammeo          0.88         0.93     0.91
Kecimen         1.00         1.00     1.00
Osmancik        0.95         0.91     0.93
second
```

Preciznost predstavlja udeo tačno predviđenih pozitivnih uzoraka među svim uzorcima koje je model označio kao pripadnike neke klase. Visoka preciznost znači da model retko pogrešno „proglasi“ uzorak da pripada određenoj klasi.

Osetljivost (*recall*) pokazuje koliko je stvarno postojećih uzoraka određene klase model uspeo da prepozna — drugim rečima, koliki deo te klase je ispravno detektovan.

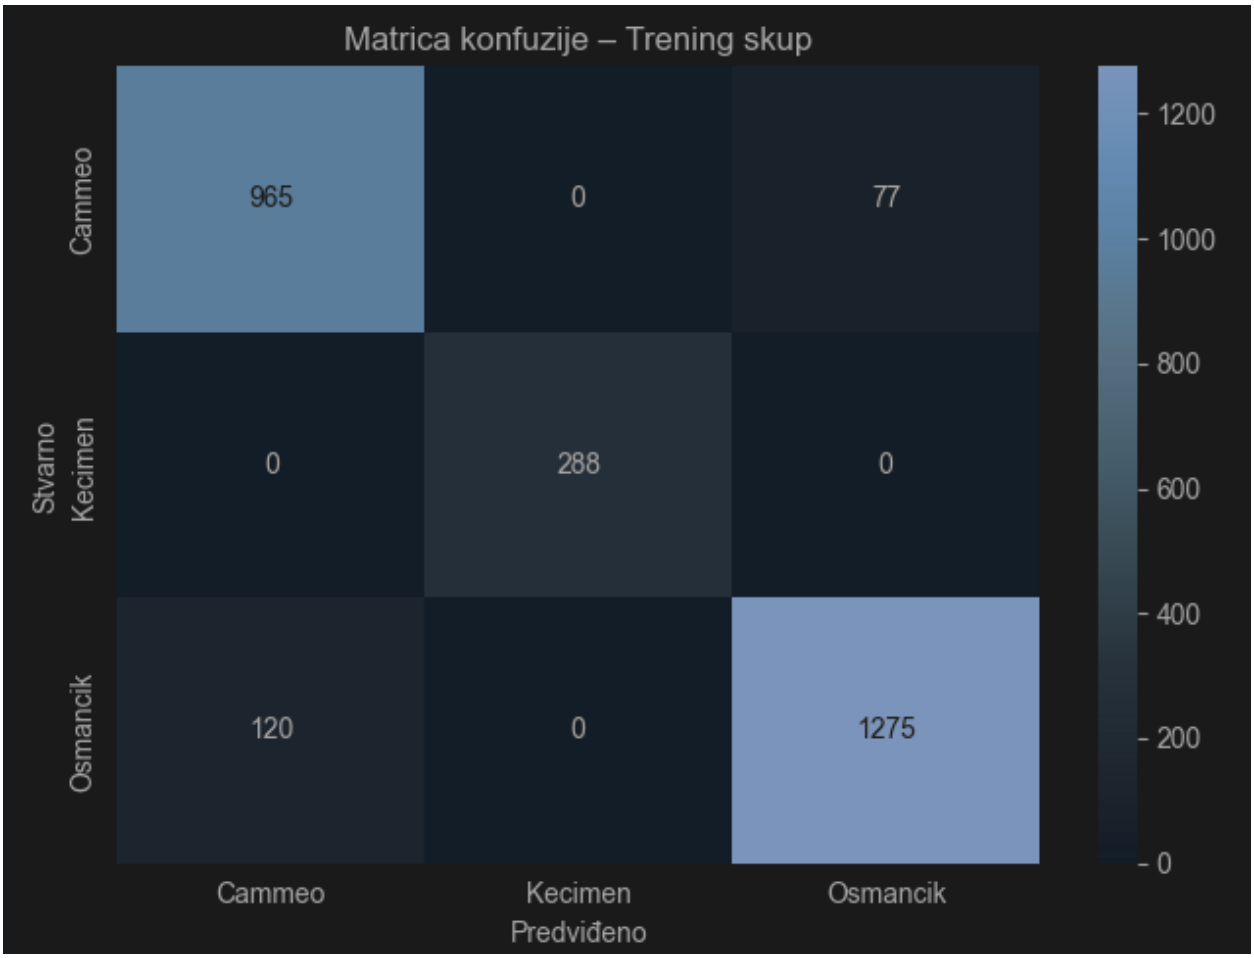
F1-skor je sredina preciznosti i osetljivosti i koristi se kao jedinstvena mera koja balansira između ova dva kriterijuma, posebno u slučajevima kada su klase neizbalansirane.

Vrednosti metrika pokazuju sledeće:

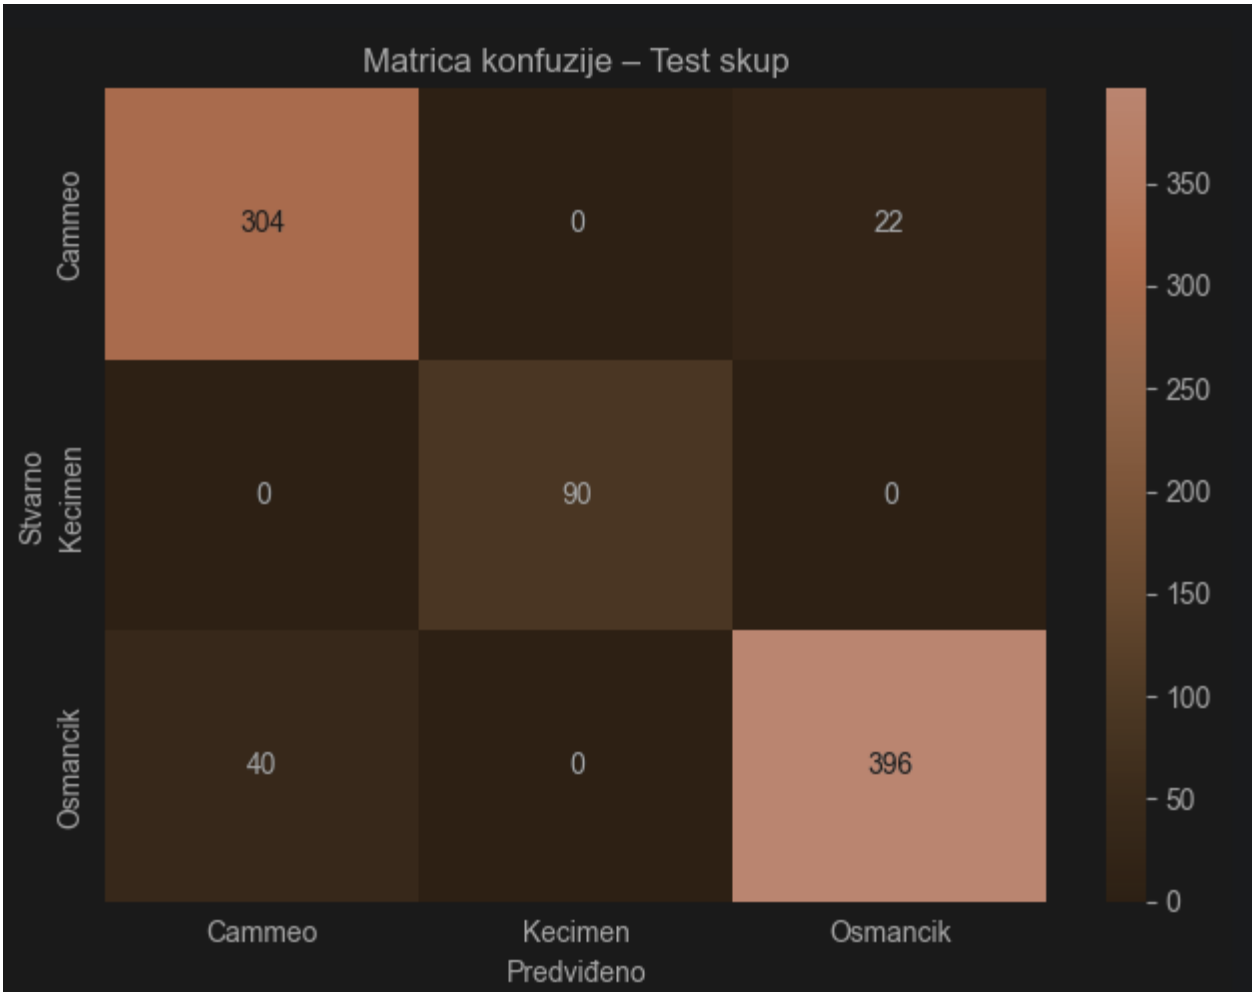
Za klasu *Cammeo,* preciznost od 0.88 i osetljivost 0.93 ukazuju da model povremeno pogrešno dodeljuje uzorke drugih klasa ovoj, ali i da uspešno prepoznaje većinu stvarnih *Cammeo* zrna. F1-skor 0.91 potvrđuje da su performanse za ovu klasu stabilne.

Za klasu *Kecimen*, sve tri vrednosti su maksimalne (1.00), što znači da model nijednom nije pogrešio – svi uzorci te klase su ispravno prepoznati i nijedan drugi uzorak nije pogrešno klasifikovan kao *Kecimen*. Ovaj rezultat je posledica jasnih razlike ove vrste pirinča u odnosu na druge.

Za klasu *Osmancik,* preciznost 0.95 i osetljivost 0.91 pokazuju da je model veoma tačan, ali povremeno pomeša nekoliko uzoraka sa klasom *Cammeo*. F1-skor 0.93 pokazuje da model generalno uspešno razlikuje ovu vrstu, iako su njene karakteristike donekle slične *Cammeo* pirinču.



Matrica konfuzije za trening skup pokazuje da je model vrlo uspešno naučio raspodelu podataka – većina uzoraka je tačno klasifikovana, a najviše grešaka nastaje pri razlikovanju sorti *Cammeo* i *Osmancik*. To je očekivano, jer su ove dve sorte po obliku i proporcijama zrna veoma slične. S druge strane, sorta *Kecimen*, iako najmanje zastupljena, gotovo da nema pogrešnih klasifikacija, što potvrđuje da su njene karakteristike dovoljno prepoznatljive.



Matrica konfuzije za test skup potvrđuje visoku tačnost modela. Na dijagonali dominiraju vrednosti, što znači da su pretpodstavke većinski tačne. Takođe se najveći broj grešaka javlja kada model meša *Cammeo* sa *Osmancik* vrstom.

Rezultati pokazuju da se uz relativno jednostavnu MLP arhitekturu može postići vrlo visoka tačnost (93%). Krive učenja su glatke, a razlika između trening i validacionih performansi je mala - što znači da nema prenaučenosti i da model generalizuje. Primena težina klasa bila je ključna da se klasa *Kecimen* izbalansira; vidljivo je da za nju nema grešaka ni na testu.

Tri ključna hiperparametra:

1. Broj neurona po slojevima

Izabrana je konfiguracija modela koja uključuje dva skrivena sloja sa 32 i 16 neurona. Cilj je bio pronaći zlatnu sredinu: arhitektura mora biti dovoljno "pametna" da nauči kompleksne obrasce iz malog skupa numeričkih obeležja, ali dovoljno "mala" da ne upamti šum u podacima – da ne dođe do *Overfitting-a*.

Razmišljanje iza ove odluke zasnovano je na sledećem:

Veći kapacitet (64-32): Iako bi ovakva mreža brže savladala grešku na trening podacima, verovatno bi dovela do velike razlike između tačnosti na trening i validacionom skupu - prenaučenost.

Manji kapacitet (16-8): Mreža bi bila veoma stabilna, ali bi prerano dostigla svoj maksimum – ne bi mogla da izvuče sve korisne informacije iz podataka.

Analiza krivihje potvrdila da je konfiguracija 32-16 bila odličan izbor. Obe krive (trening i validacija) su se brzo "uhvatile" jedna uz drugu i stabilizovale već oko 10. do 12. epohe, bez ikakve divergencije.

2. Stopa učenja

Ovo je kritičan hiperparametar koji određuje veličinu koraka koje model preduzima prilikom ažuriranja svojih težina na osnovu izračunate greške. Korišćena je vrednost lr = 0.0004 uz Adam optimizator. Ova vrednost je namerno izabrana da bude nešto manja od uobičajene stope 0.001. Cilj je bio da model uči na siguran i stabilan način:

Mirne krive: Manja stopa učenja osigurava da validacione krive budu "mirne", bez naglih oscilacija, koje su obično znak prevelike stope učenja.

Pouzdanost: Model je pravio manje, ali pouzdanije korake u potrazi za optimalnim rešenjem

I ovde su rezultati potvrdili ispravnost izbora: preciznost na validacionom skupu je brzo prešla granicu od 90% i ostala savršeno stabilna. Veća stopa učenja bi verovatno brže smanjila grešku u početku, ali bi rizikovala preoscilaciju oko optimuma, dok bi manja stopa nepotrebno usporila ceo proces učenja.

3. Veličina batch-a.

Na kraju, morali smo definisati koliko uzoraka model obrađuje istovremeno pre nego što ažurira svoje težine. Odabrana je veličina batch_size = 32, što predstavlja najbolji kompromis za ovakav tip podataka.

Prednosti izbora 32:

Dovoljno mali: Batch od 32 je dovoljno mali da unese korisnu stohastičnost – to znači da model pri svakom koraku ne vidi sve uzorke odjednom, već manji deo, što mu pomaže da bolje generalizuje.

Dovoljno veliki: Istovremeno, dovoljno je velik da proces učenja bude stabilan i brz.

U praksi, rad sa manjim batchevima (16) obično dovodi do većih oscilacija u grešci, dok veći batchevi (64 ili 128) mogu dovesti do učenja koje je stabilno, ali često dovodi do lošijih konačnih performansi.

Model potpuno povezane neuralne mreže sa dva skrivena ReLU sloja, treniran pomoću *Adam* optimizatora i *early stopping-a,* pokazao je visok stepen efikasnosti u klasifikaciji vrsta pirinča. Nakon standardizacije ulaza i primene težina klasa, postignuta je ukupna tačnost od 93%, uz uravnotežene vrednosti preciznosti i osetljivosti po svim klasama.

Greške se uglavnom javljaju pri razlikovanju *Cammeo* i *Osmancik* vrsti pirinča, što je posledica njihove morfološke sličnosti, dok je klasa *Kecimen* potpuno pravilno prepoznata. Dobijeni rezultati potvrđuju da je odabrana arhitektura jednostavna, ali dovoljno snažna da uspešno nauči obrasce u podacima i generalizuje ih na nove primere.

Zaključak je da model ostvaruje odličan balans između tačnosti i stabilnosti, čime predstavlja optimalno rešenje za klasifikaciju zrna pirinča u ovom zadatku.

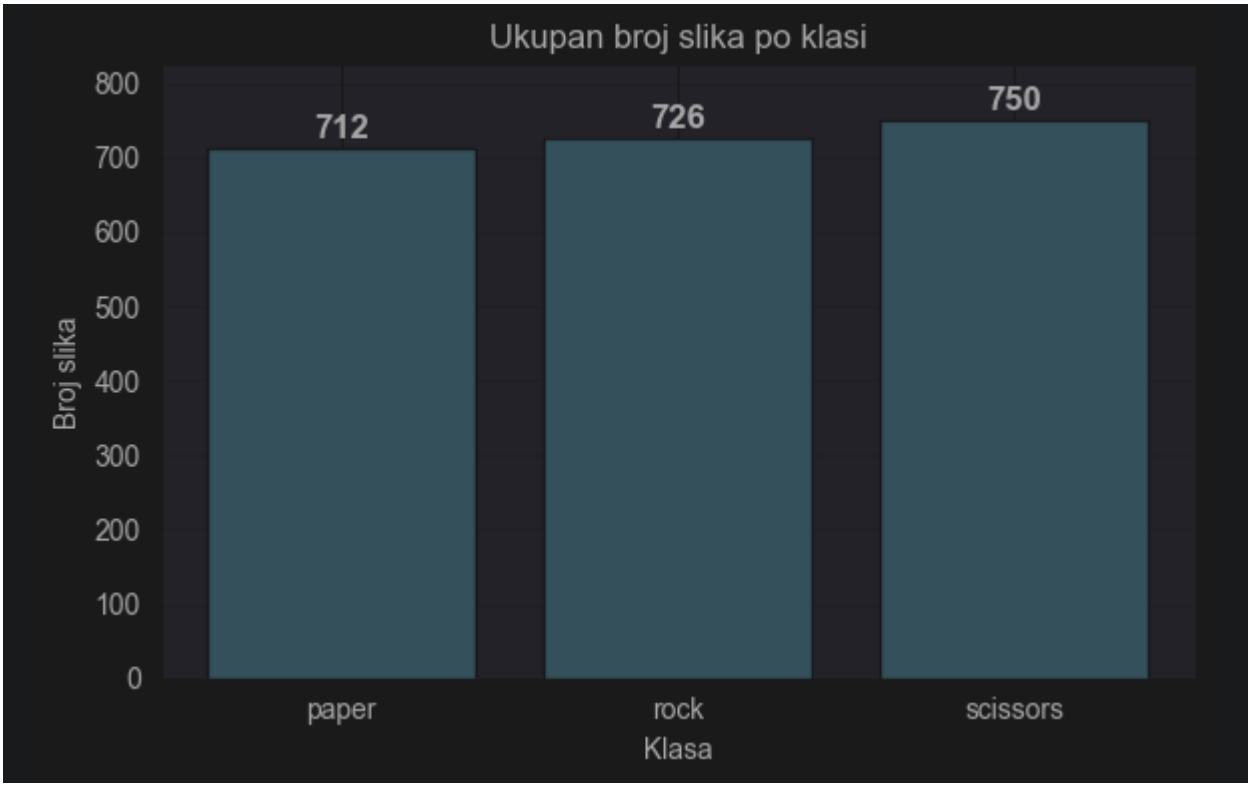
2. Projektovanje potpuno konvolucione neuralne mreže

Zadatak se odnosi na klasifikaciju slika gestova ruke koji predstavljaju tri klase igre:

Rock – Paper – Scissors (kamen, papir, makaze)

Problem je tipičan primer višeklasne klasifikacije slika, pri čemu model treba da prepozna kojoj od klasa pripada ulazna fotografija.

Korišćen je skup podataka sa platforme Kaggle (drgfreeman/rockpaperscissors). Skup sadrži ukupno nekoliko hiljada slika dimenzija 64×64 piksela, ravnomerno raspoređenih u tri klase: paper, rock, scissors.



Histogram prikazuje da su klase dobro uravnotežene – svaka ima približno jednak broj primera (712 za paper, 726 za rock, 750 za scissors). Takva struktura skupa omogućava treniranje bez potrebe za dodatnim balansiranjem klasa, što pojednostavljuje proces obuke.

Pre nego što su slike poslate u CNN model, izvršeno je nekoliko koraka pretprocesiranja:

Podela na skupove:

Skup podataka je podeljen na trening (80%) i test (20%) podskupove. Korišćena je fiksna vrednost semena (seed=123) kako bi se osigurala reproduktivnost rezultata — svaki put kada se kod pokrene, ista slika će biti u istom skupu.

Normalizacija:

Slike su skalirane na raspon vrednosti piksela od 0 do 1 pomoću sloja *layers.Rescaling(1.0 / 255)*. Ovaj korak je neophodan jer visoke vrednosti piksela mogu pokvariti učenje same mreže; skaliranjem se ubrzava učenje i stabilizuju gradijenti tokom propagacije.

Augmentacija podataka:

Ova tehnika je ključna za povećanje raznovrsnosti trening skupa slika bez prikupljanja novih podataka i predstavlja efikasan način borbe protiv *overfitting-a*. Primenjene su sledeće transformacije:

- Horizontalno preslikavanje - *RandomFlip("horizontal")*
- Mala rotacija - *RandomRotation(0.1)*
- Slučajno uvećanje - *RandomZoom(0.1)*

Ove operacije generišu blage varijacije u orijentaciji, osvetljenju i položaju ruke na slici. Time mreža postaje sposobnija da prepozna objekte u realnim, različitim uslovima.

Model je realizovan kao sekvencijalna CNN mreža, čija se arhitektura sastoji od tri konvoluciona bloka i jednog potpuno povezanog dela:

```
model = Sequential([
    augmentacija,
    layers.Rescaling(1.0 / 255, input_shape=(64, 64, 3)),
    layers.Conv2D(16, 3, padding="same", activation="relu", kernel_regularizer=l2(0.01)),
    layers.MaxPooling2D(),
    layers.Conv2D(32, 3, padding="same", activation="relu", kernel_regularizer=l2(0.01)),
    layers.MaxPooling2D(),
    layers.Conv2D(64, 3, padding="same", activation="relu", kernel_regularizer=l2(0.01)),
    layers.Dropout(0.3),
    layers.Flatten(),
    layers.Dense(128, activation="relu", kernel_regularizer=l2(0.01)),
    layers.Dropout(0.3),
    layers.Dense(broj_klasa, activation="softmax")
])
```

Prvi blokovi mreže koriste konvolucione slojeve - *Conv2D* čija je osnovna funkcija izdvajanje prostornih obrazaca iz slike, kao što su ivice, konture šake i oblici prstiju. Broj filtera se progresivno povećava, od 16 ka 32 ka 64, čime se omogućava mreži da uči sve apstraktnije i kompleksnije karakteristike kako podaci prolaze kroz dublje slojeve. U ovim konvolucionim slojevima koristi se *ReLU* aktivaciona funkcija koja ubrzava učenje uvođenjem nelinearnosti.

Iza svakog konvolucionog sloja nalazi se *MaxPooling2D* sloj koji služi za sažimanje informacija i smanjenje prostorne veličine obrađene slike. Ovo smanjenje ne samo da smanjuje računarsku složenost, već i obezbeđuje ključnu translacionu otpornost, što znači da model uspešno prepoznaje oblik ruke bez obzira na njen tačan položaj unutar slike.

Nakon konvolucionog dela, model se "spljoštava" – *Flatten* i ulazi u potpuno povezani deo, koji uključuje gusti sloj sa 128 neurona. Kao poslednji sloj, koristi se *Softmax* izlazni sloj. Njegova ključna uloga je da konačne rezultate mreže pretvori u distribuciju verovatnoća, jasno pokazujući šansu da slika pripada jednoj od tri moguće klase

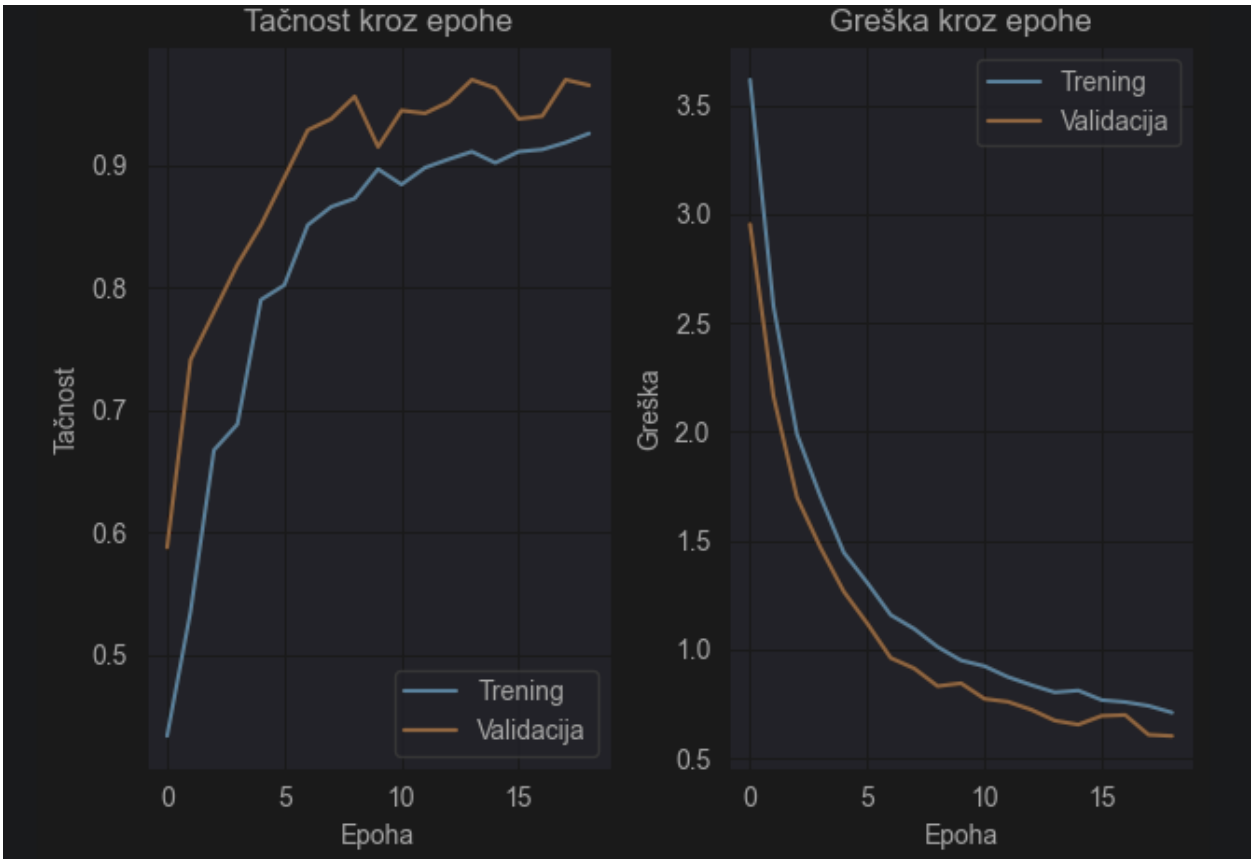
Da bi se osigurala dobra generalizacija modela, primenjena su dva mehanizma regularizacije:

Dropout: Slojevi *Dropout(0.3)* uvode nasumično "isključivanje" 30% neurona tokom obuke. Time se sprečava da se model previše osloni na bilo koji pojedinačni neuron ili skup neurona, značajno smanjujući rizik od *overfitting-a*.

L2 regularizacija: Primenjena je i L2 regularizacija *kernel_regularizer=l2(0.01)* na težinama konvolucionih i gustih slojeva. Ova tehnika dodaje kaznenu funkciju na težine, prisiljavajući model da koristi manje ekstremne vrednosti težina, čime se podstiču jednostavnija rešenja.

Model je treniran korišćenjem *Adam* optimizatora sa stabilnom stopom učenja od 0.0001. Odabrana funkcija greške je *SparseCategoricalCrossentropy*, koja je najpogodnija jer su oznake klasa u skupu podataka predstavljene celobrojnim vrednostima umesto *one-hot* vektorima. Takođe, primenjen je *Early Stopping* mehanizam sa tolerancijom od 5 epoha (*patience=5*). Ova strategija prekida obuku kada se validaciona tačnost ne poboljša u tom periodu, čime se sprečava nepotrebno učenje i obezbeđuje se da se vrate najbolje generalizujuće težine modela.

Treniranje je sprovedeno u do 50 epoha, ali je zahvaljujući ranoj obustavi konvergencija postignuta znatno ranije.



Na levoj strani prikazana je promena tačnosti kroz epohe, a na desnoj promena greške kroz epohe.

Može se primetiti da se tačnost brzo povećava tokom prvih deset epoha, nakon čega se stabilizuje na oko 97%, dok se funkcija greške postepeno smanjuje i ulazi u stabilnu zonu.

Grafički prikaz procesa obuke pokazuje da su krive tačnosti i gubitka za trening i validacioni skup vrlo blizu jedna drugoj tokom celog procesa. Ova bliska udaljenost je indikator uspešne obuke: to znači da mreža nije prenaučena, već da je naučila opšta pravila. Drugim rečima, model je zadržao dobru sposobnost generalizacije na nepoznate (validacione) slike.

Nakon obuke, model je testiran na nezavisnom delu skupa podataka koji nije korišćen u fuzzy treniranja.

Postignuta je ukupna tačnost od 97%, što znači da mreža ispravno klasifikuje gotovo sve slike iz test skupa. Ovaj rezultat ukazuje na uspešnu generalizaciju modela – sposobnost da prepozna nove, ranije neviđene primere.

```
Ukupna tačnost: 0.97

Performanse po klasama:

              Preciznost  Osetljivost  F1-skor
paper               0.98         0.93     0.95
rock                0.97         0.99     0.98
scissors            0.97         0.99     0.98
```

Preciznost predstavlja udeo tačno predviđenih pozitivnih uzoraka među svim uzorcima koje je model označio kao pripadnike neke klase. Visoka preciznost znači da model retko pogrešno „proglasi“ uzorak da pripada određenoj klasi.

Osetljivost (*recall*) pokazuje koliko je stvarno postojećih uzoraka određene klase model uspeo da prepozna — drugim rečima, koliki deo te klase je ispravno detektovan.

F1-skor je sredina preciznosti i osetljivosti i koristi se kao jedinstvena mera koja balansira između ova dva kriterijuma, posebno u slučajevima kada su klase neizbalansirane.

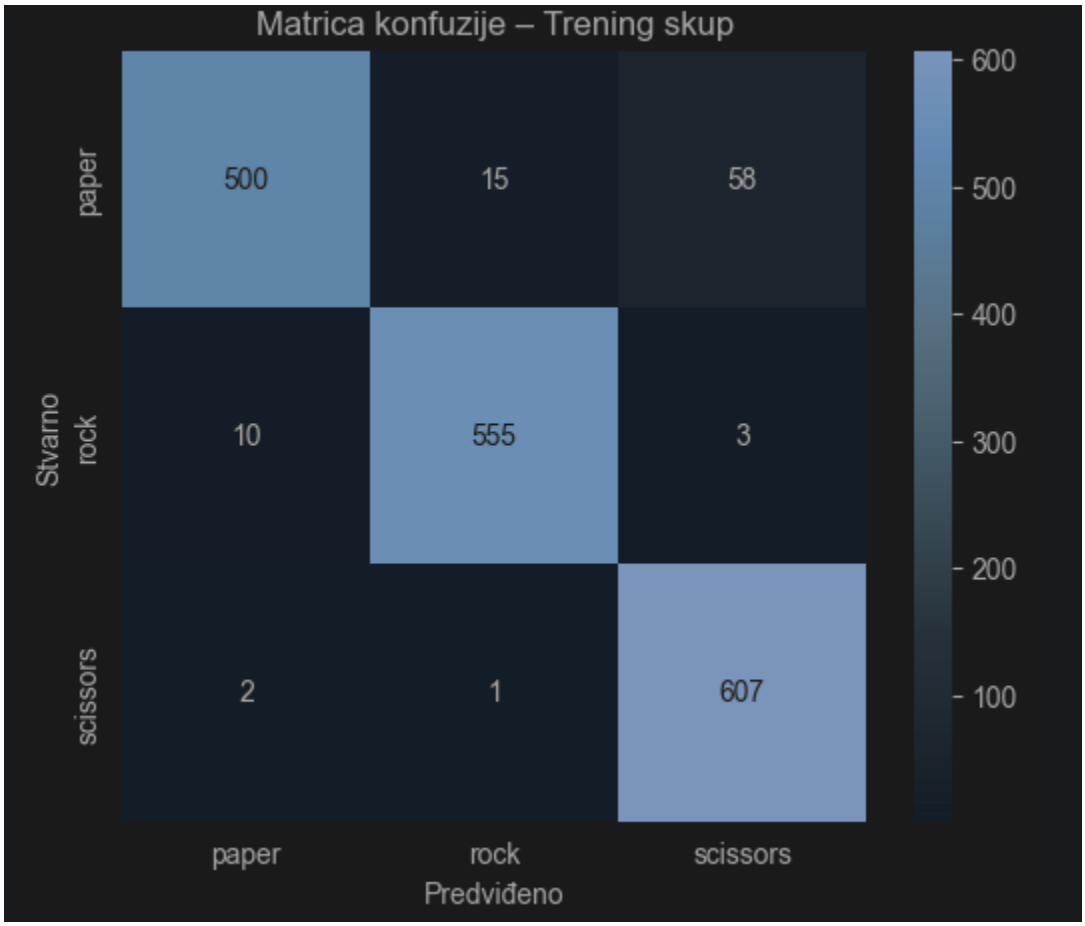
Vrednosti metrika pokazuju sledeće:

Sve klase imaju vrlo visoke i međusobno ujednačene vrednosti, što znači da model nema izraženu pristrasnost prema bilo kojoj klasi. Blago niža osetljivost klase paper (0.93) nam govori da model povremeno promaši nekoliko primera *papira*, najverovatnije zbog sličnosti u konturi i osvetljenju sa klasom *scissors*.

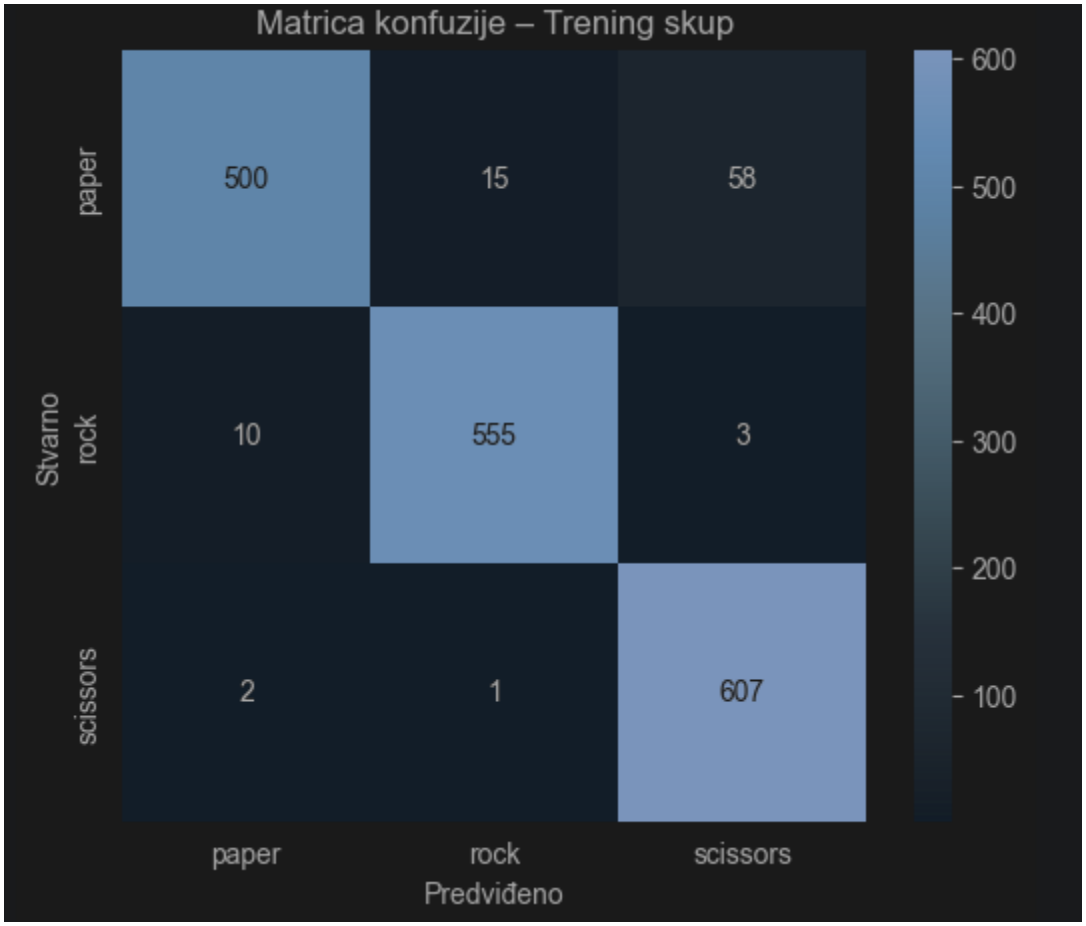
S druge strane, klase *rock* i *scissors* postižu gotovo savršene rezultate (99% osetljivosti), što potvrđuje da mreža vrlo uspešno uočava njihove karakteristične oblike.

Sve u svemu, visoke i stabilne vrednosti svih metrika potvrđuju da model pravilno uči vizuelne obrasce svake klase i da postiže uravnotežene performanse na svim kategorijama slika.

Matrice konfuzije predstavljaju detaljan uvid u način na koji model klasifikuje slike svake klase, prikazujući koliko je uzoraka svake stvarne klase ispravno ili pogrešno svrstano u pojedine kategorije. Vrednosti na glavnoj dijagonali predstavljaju tačne klasifikacije, dok se van dijagonale nalaze pogrešne dodele.



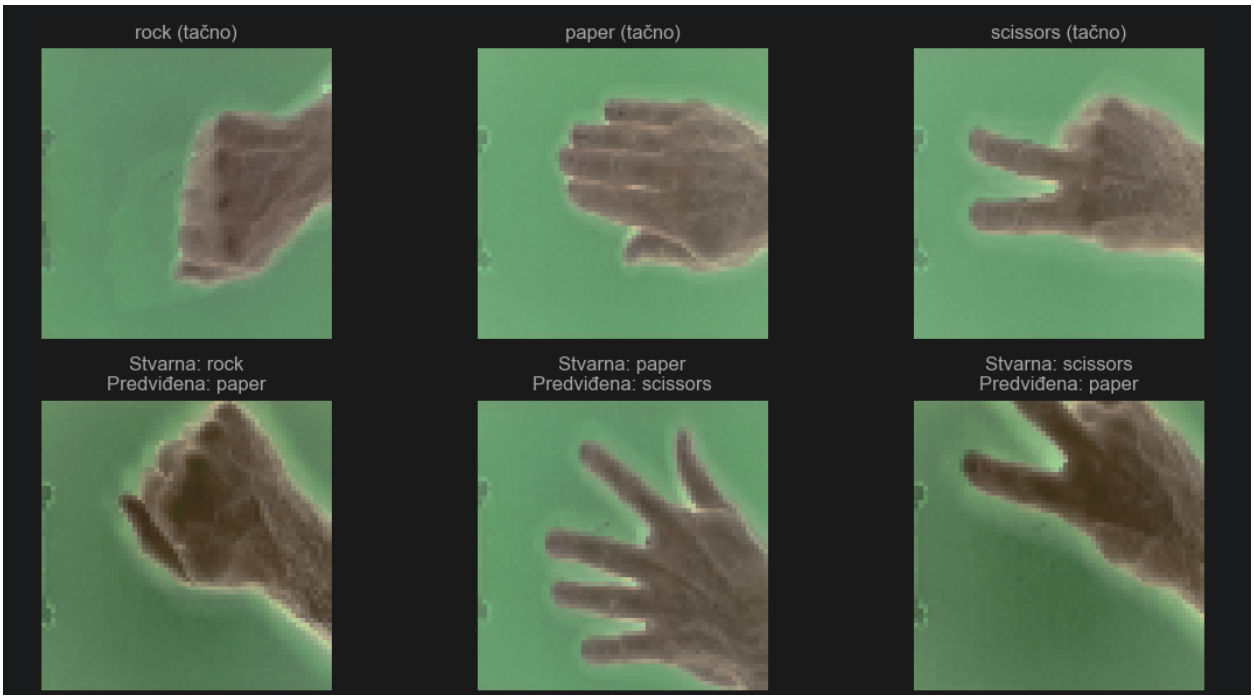
Na ovoj matrici – za trening skup, uočava se da model gotovo savršeno prepoznaje sve primere; sve se vidi na dijagonali, što ukazuje da je mreža pravilno naučila obrasce karakteristične za svaku klasu. Broj pogrešno klasifikovanih uzoraka je minimalan, što potvrđuje da mreža ima dobru sposobnost učenja i da proces treniranja nije doveo do prenaučenosti, budući da je preciznost visoka, ali ne 100%.



Na matrici za test skup rezultati su slični i potvrđuju visoku generalizaciju. Većina slika je pravilno klasifikovana, a manji broj grešaka javlja se između klasa *paper* i *scissors*. Kao što je prethodno spomenuto, model povremeno pomeša slike otvorene ruke - *paper* sa slikama koje prikazuju dva prsta - *scissors*, što je očekivano jer su ta dva gesta slična i često zavise od ugla fotografisanja ili osvetljenja.

S druge strane, klasa *rock* ima gotovo savršeno prepoznavanje – tačnost za ovu klasu je oko 99%. To je zato što je gest zatvorene pesnice vrlo karakterističan i lako se razlikuje od ostalih klasa, čak i pri promenama pozadine i osvetljenja.

U zaključku, matrice konfuzije potvrđuju da je model naučio stabilne i jasne granice između klasa. Preostale greške nisu posledica loše arhitekture mreže, već prirodne vizuelne sličnosti između pojedinih gestova, što je uobičajeno kod ovakvih problema vizuelne klasifikacije.



Gornji red prikazuje primere ispravno klasifikovanih slika za svaku klasu (*rock, paper, scissors*), dok donji red prikazuje pogrešne predikcije.

Može se primetiti da se većina grešaka događa kod lošije osvetljenih slika ili onih sa neuobičajenim položajem ruke, što potvrđuje da su takve varijacije glavni izazov za model.

Uprkos tome, greške su retke i uglavnom granične, što govori o stabilnosti mreže.

Dobijeni rezultati pokazuju da je ova konvoluciona neuralna mreža veoma uspešna u rešavanju zadatka klasifikacije slika gestova *rock–paper–scissors*. Kombinacija konvolucionih slojeva, regularizacije i *dropout-a* omogućila je da model postigne visoku tačnost uz očuvanu sposobnost generalizacije.

Primena augmentacije podataka je povećala otpornost na promene položaja, orijentacije i osvetljenja ruku na slikama. Zahvaljujući tome, mreža je naučila da prepoznaje ključne vizuelne karakteristike svake klase, a da pritom ne zavisi od konkretnih uslova u kojima su slike snimljene.

Model postiže ukupnu tačnost od 97% i izuzetno visoke vrednosti F1-skora za sve klase, što ukazuje na stabilne i uravnotežene performanse. Većina grešaka javlja se između klasa *paper* i *scissors*, koje su vizuelno najsličnije, dok je klasa *rock* gotovo savršeno prepoznata zahvaljujući jasno izraženom obliku pesnice.

Zaključak je da ova CNN mreža pokazuje odličan balans između složenosti, tačnosti i generalizacione sposobnosti, pa se može smatrati pouzdanim i efikasnim rešenjem za problem klasifikacije slika ovog tipa.

3. Projektovanje fuzzy regulatora

Zadatak projekta obuhvata projektovanje fuzzy regulatora za složen objekat upravljanja, definisan sledećom prenosnom funkcijom:

$$G(s) = \frac{-0{,}2s + 0{,}0{,}1}{(s + 0{,}1)^2} e^{-4s}$$

Neminimalna faza:

Prisustvo nule u desnoj poluravni (koja potiče od člana *-0.2s + 0.01*) klasifikuje ovaj sistem kao neminimalno fazni. Ova karakteristika dovodi do neželjene pojave inicijalnog preskoka odziva u suprotnom smeru (*undershoot*), pre nego što sistem počne da se kreće ka željenoj referentnoj vrednosti.

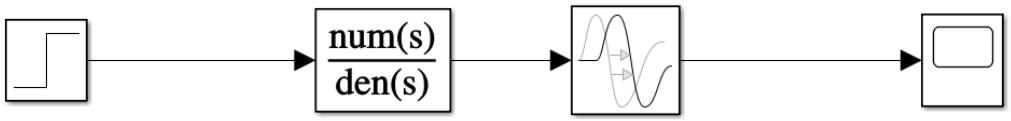
Značajno kašnjenje:

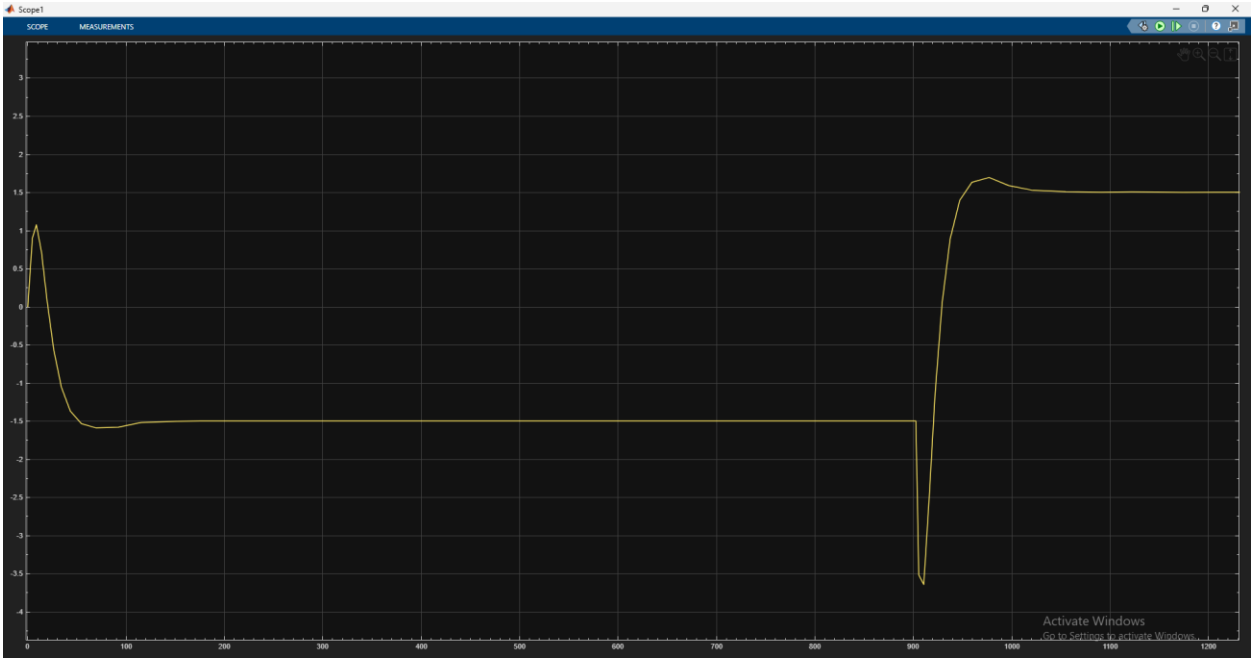
Sistem dodatno poseduje kašnjenje od četiri sekunde – faktor e^{-4s}, što otežava upravljanje i zahteva prediktivni pristup u regulaciji.

Referentni signal r je definisan u opsegu $r \in [-1, +1]$,dok je upravljački signal u ograničen na $u \in [-1.5, +1.5]$

Glavni zadatak projektovanog fuzzy regulatora je brzo i stabilno praćenje referentne vrednosti bez neželjenog prenapona, minimalizacija greške u stacionarnom (dugoročnom) režimu, koa i postizanje visoke otpornosti na poremećaje, čime se osigurava stabilan rad sistema u realnim uslovima.

Pre početka projektovanja fuzzy kontrolera, izvršena je analiza samog objekta upravljanja. Model je testiran na step pobudu koja se kretala u opsegu upravljačkog signala, od -1.5 do 1.5.





Analiza odziva je potvrdila pretpostavljene izazove u vezi sa prenosnom funkcijom sistema:

Na dijagramu je jasno uočljiv negativni prelazni preskok odmah nakon promene ulaznog signala. Ovo je direktna posledica neminimalno faznog ponašanja sistema (uzrokovanog nulom u desnoj poluravni). Odziv kreće u suprotnom smeru od željenog, pre nego što se usmeri ka referentnoj vrednosti, što nam govori da je fuzzy najbolje rešenje. Zbog svoje inherentne robustnosti i sposobnosti da efikasno obrađuje neprecizne informacije, fuzzy pristup je optimalan za prevazilaženje složene dinamike neminimalno faznog sistema sa kašnjenjem.

Za projektovanje je korišćen intuitivni pristup, gde su pravila i funkcije pripadnosti podešeni eksperimentalno, tako da se postigne stabilan odziv sa što manjom greškom.

Regulator je realizovan kao Mamdani tip fuzzy sistema sa dva ulaza i jednim izlazom. Ulazne veličine su:

- greška (e) — razlika između referentne i izlazne vrednosti sistema
- promena greške (de) — prvi izvod greške u vremenu

Izlazna veličina je promena upravljačkog signala (du).

Korišćeni univerzumi:

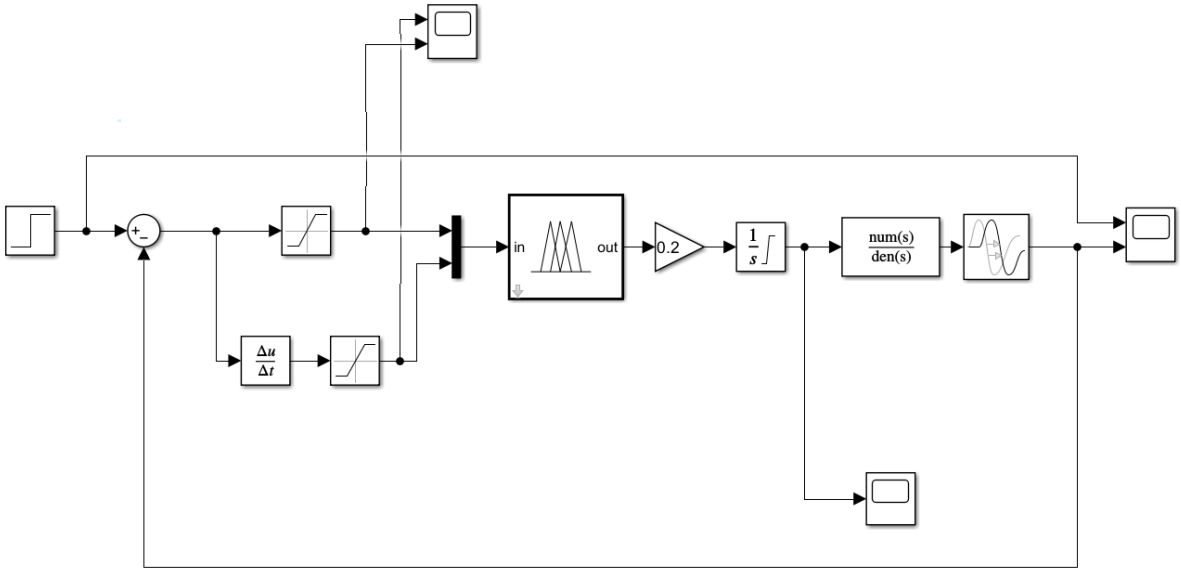
- $e \in [-2, 2]$
- $de \in [-1, 1]$
- $du \in [-0.2, 0.2]$

U okviru FIS-a primenjene su trapezne i Gausove funkcije pripadnosti, čime je omogućeno glatko prelaženje između zona i stabilno ponašanje sistema.

Eksperimentalnim putem je definisano 7 pravila, koja predstavljaju tipične kombinacije odnosa greške i njene promene, kao na primer:

- Ako su e = NB i de = NB, onda je du = NB
- Ako su e = NM i de = NM, onda je du = NS
- Ako su e = ZE i de = ZE, onda je du = ZE
- Ako su e = PM i de = NM, onda je du = PS
- Ako su e = PM i de = PM, onda je du = PM
- Ako su e = PB i de = ZE, onda je du = PB
- Ako su e = PB i de = PS, onda je du = PB

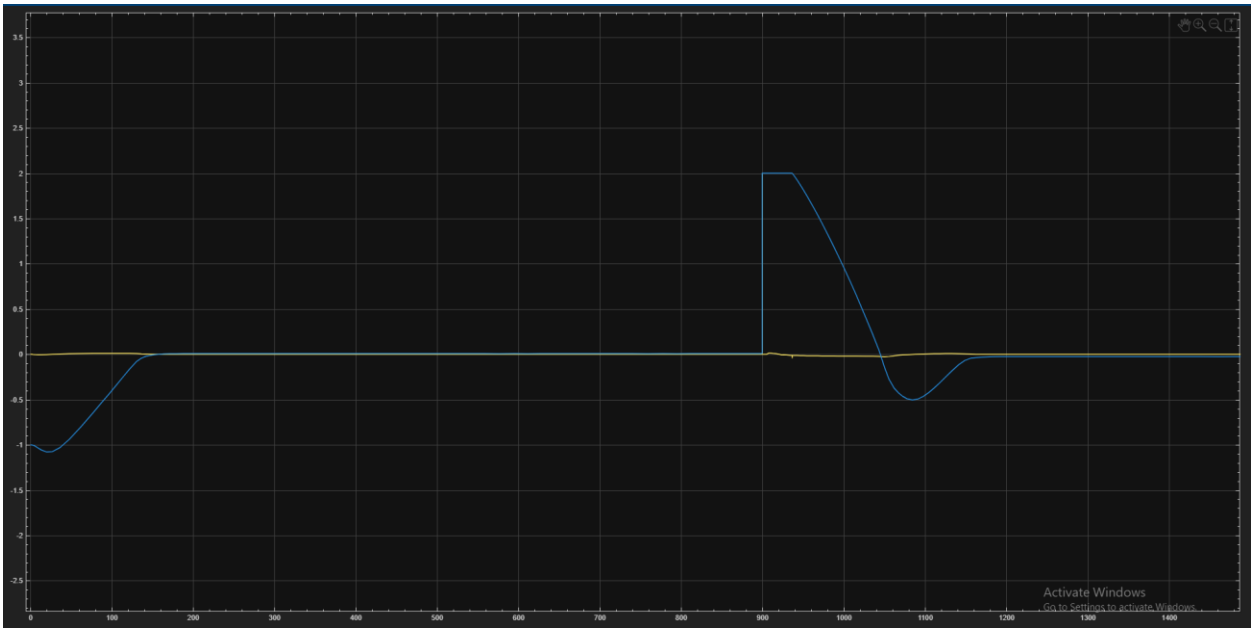
Ovim pravilima postignuto je da sistem reaguje agresivno kad postoji veliko odstupanje, a blago kada se približava referenci.



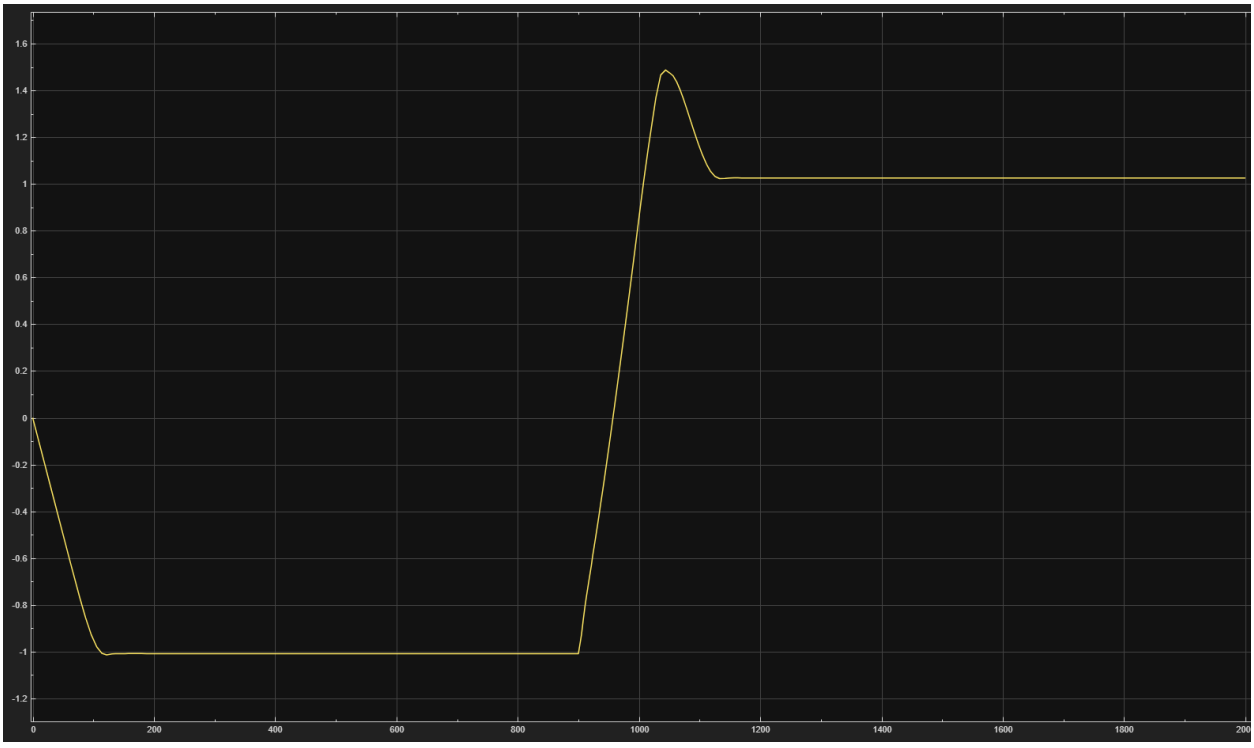
Model je organizovan u zatvorenoj sprezi sa objektom upravljanja, gde se greška i njen izvod izračunavaju u realnom vremenu.

Na izlazu fuzzy sistema nalazi se Gain blok sa faktorom 0.2, kojim se ublažava prevelika amplituda izlaza. Izlaz se zatim integriše pomoću Integrator bloka, čime se dobija realan upravljački signal. Da bi se sprečilo prekoračenje, izlaz iz integratora prolazi kroz Saturation blok koji ograničava signal na [−1.5, +1.5].

Svi odzivi su analizirani sa vremenom simulacije od 2000, čime je omogućeno detaljno posmatranje različitih ponašanja sistema tokom dužeg vremenskog perioda.

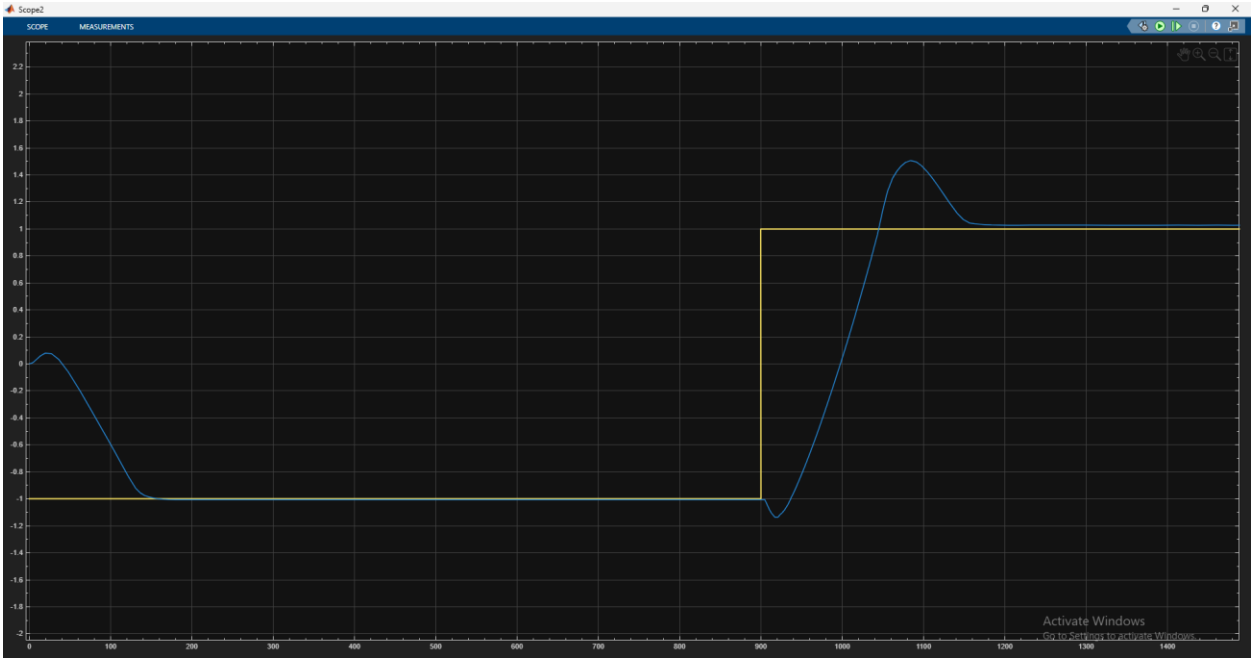


Plava linija predstavlja grešku, dok žuta prikazuje njen prvi izvod. Vidi se da greška brzo teži nuli, osim u trenutku nagle promene referentne vrednosti, kada se javlja kratkotrajan skok. Promena greške prati dinamiku sistema, što pokazuje da fuzzy regulator reaguje u skladu sa promenama.



Signal upravljanja ima glatke prelaze i zadržava se unutar ograničenja [−1.5, +1.5].

Pik koji se javlja oko T ≈ 1000 odsečen je na gornjoj granici zbog saturacije. U stacionarnom stanju, sistem postiže stabilan izlaz i mala odstupanja reda veličine 10^{-2}, što je sasvim prihvatljivo.



Izlaz sistema (plavo) uspešno prati referentni signal (žuto). Početni negativni preskok je rezultat neminimalne faze objekta, ali nakon prolaznog stanja sistem se stabilizuje i greška teži nuli.

Odziv je brz, bez značajnih oscilacija i sa stabilnim prelaznim ponašanjem.

Dobijeni rezultati potvrđuju da fuzzy regulator efikasno stabilizuje ovaj fazni sistem i omogućava precizno praćenje zadate reference. Prednost fuzzy pristupa u odnosu na klasične PID regulatore ogleda se u njegovoj prilagodljivosti – reakcija zavisi od konteksta greške i njene promene, pa sistem reaguje brzo kada je greška velika, a smireno kada se približava cilju.

Analizom odziva može se zaključiti:

- sistem reaguje stabilno bez prenapona
- vreme potrebno da sistem pređe iz nestabilnog u stabilno stanje kratko
- u stacionarnom režimu greška je minimalna
- upravljački signal je u dozvoljenim granicama

Projektovani fuzzy regulator pokazao je da intuitivni pristup može obezbediti stabilno i precizno upravljanje.

Dobijeni odziv pokazuje da sistem uspešno prati referentnu vrednost, a greška u stacionarnom stanju je zanemarljiva.

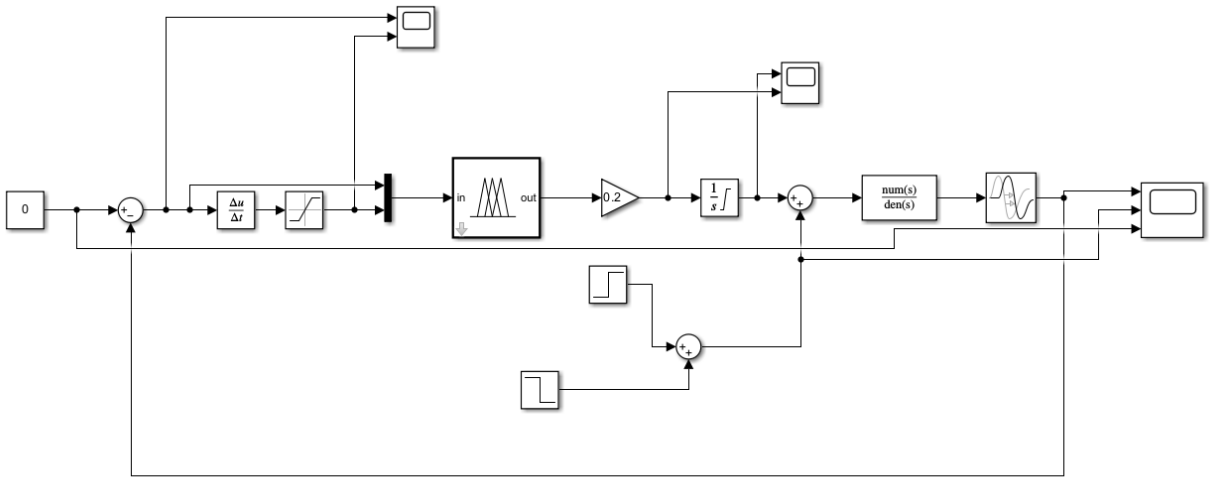
Zahvaljujući kombinaciji Mamdani fuzzy logike, inkrementalnog upravljanja i saturacije, regulator postiže gladak, stabilan i fizički izvodljiv odziv.

Ovakva konfiguracija se pokazala kao optimalna ravnoteža između brzine odziva i stabilnosti sistema, potvrđujući prednost fuzzy pristupa u nelinearnim i sporim procesima.

Fuzzy regulator sa poremećajem

Izvršena je nadogradnja modela radi ispitivanja otpornosti sistema na poremećaje. Osnovna funkcionalna struktura i fuzzy pravila (FIS sistem) su neizmenjena.

Šema je proširena dodavanjem specifičnih blokova koji su modelovali i uvodili spoljašnje poremećaje u proces upravljanja. Ova modifikacija je ključna, jer je omogućila testiranje ponašanja sistema u realnijim, narušenim radnim uslovima, umesto samo u idealnom okruženju.



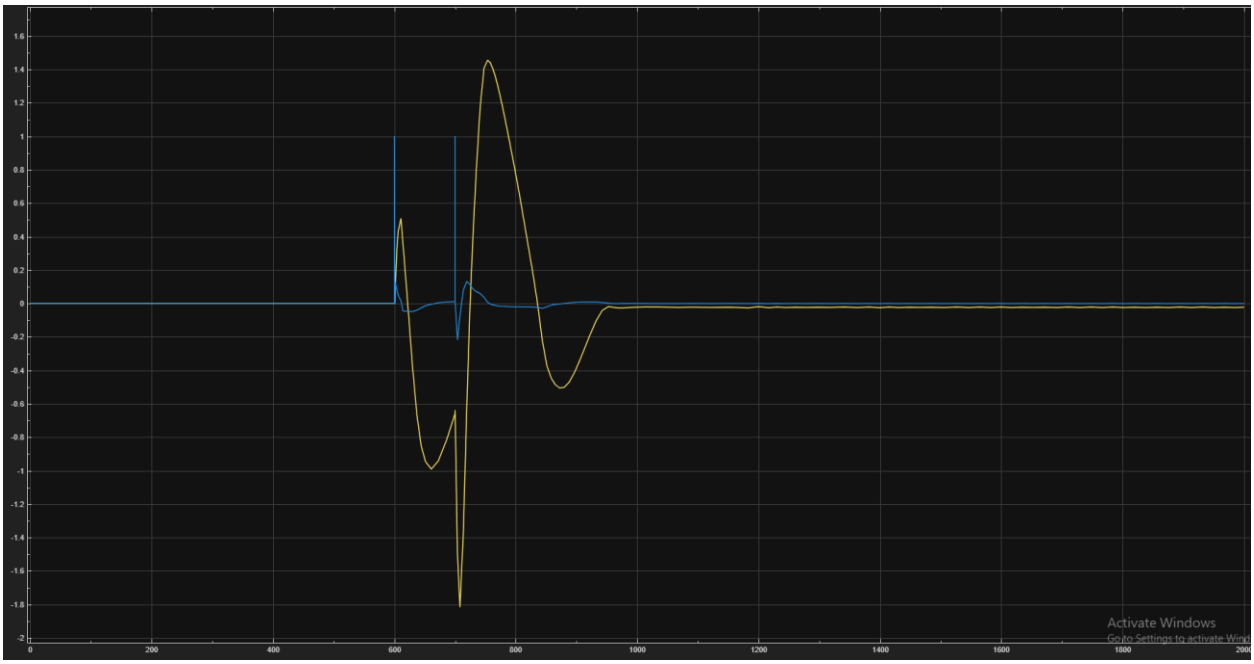
Ulazni signal predstavlja referencu podešenu na konstantnu vrednost nula, što znači da je cilj regulatora da održava izlaz sistema u stanju ravnoteže uprkos pojavi poremećaja. Na samom početku, Sum blok računa grešku (e) kao razliku između referentne vrednosti i stvarne izlazne vrednosti sistema. Dobijeni signal se zatim prosleđuje u Derivative blok, koji izračunava promenu greške (de) – odnosno brzinu promene odstupanja.

Oba signala (e i de) dovode se na ulaz fuzzy kontrolera, koji generiše upravljački signal u skladu sa prethodno definisanim fuzzy pravilima. Kao i ranije, korišćen je Mamdani tip fuzzy sistema sa dva ulaza i jednim izlazom, sa istim podešavanjima.

Na izlazu fuzzy sistema nalazi se Gain blok sa faktorom 0.2, kojim se ublažava prevelika amplituda izlaza. Izlaz se zatim integriše pomoću Integrator bloka, čime se dobija realan upravljački signal.

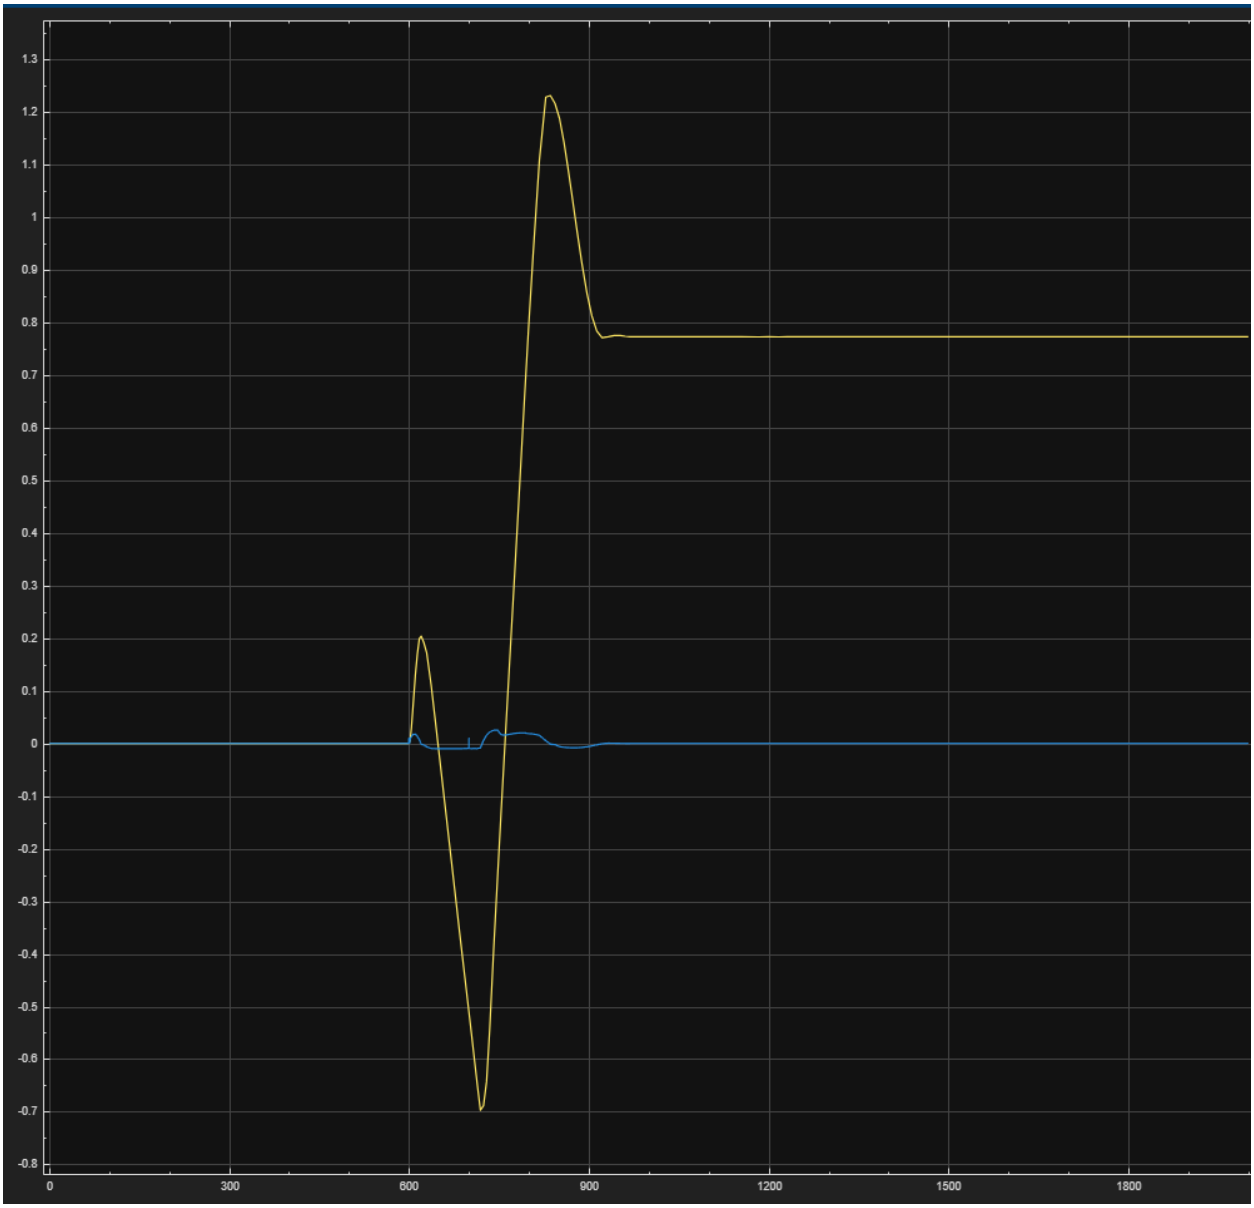
Kako bi se ispitao odziv sistema na spoljašnje smetnje, u model su dodata dva Step bloka koji simuliraju poremećaje. Prvi poremećaj se pojavljuje u ranijem trenutku i uzrokuje nagli skok signala, dok drugi ima suprotan efekat i deluje kasnije, stvarajući promenu u obrnutom smeru. Ovi poremećaji se sabiraju i zatim dodaju signalu upravljanja, čime se u realnim uslovima oponašava delovanje spoljašnjih smetnji na proces.

Izlaz fuzzy regulatora se onda se dovodi na ulaz objekta upravljanja predstavljenog funkcijom prenosa G(s), koja uključuje kašnjenje (Transport Delay) i dinamičko ponašanje sistema. Na kraju, postavljeni su Scope blokovi radi praćenja odziva svih relevantnih signala.



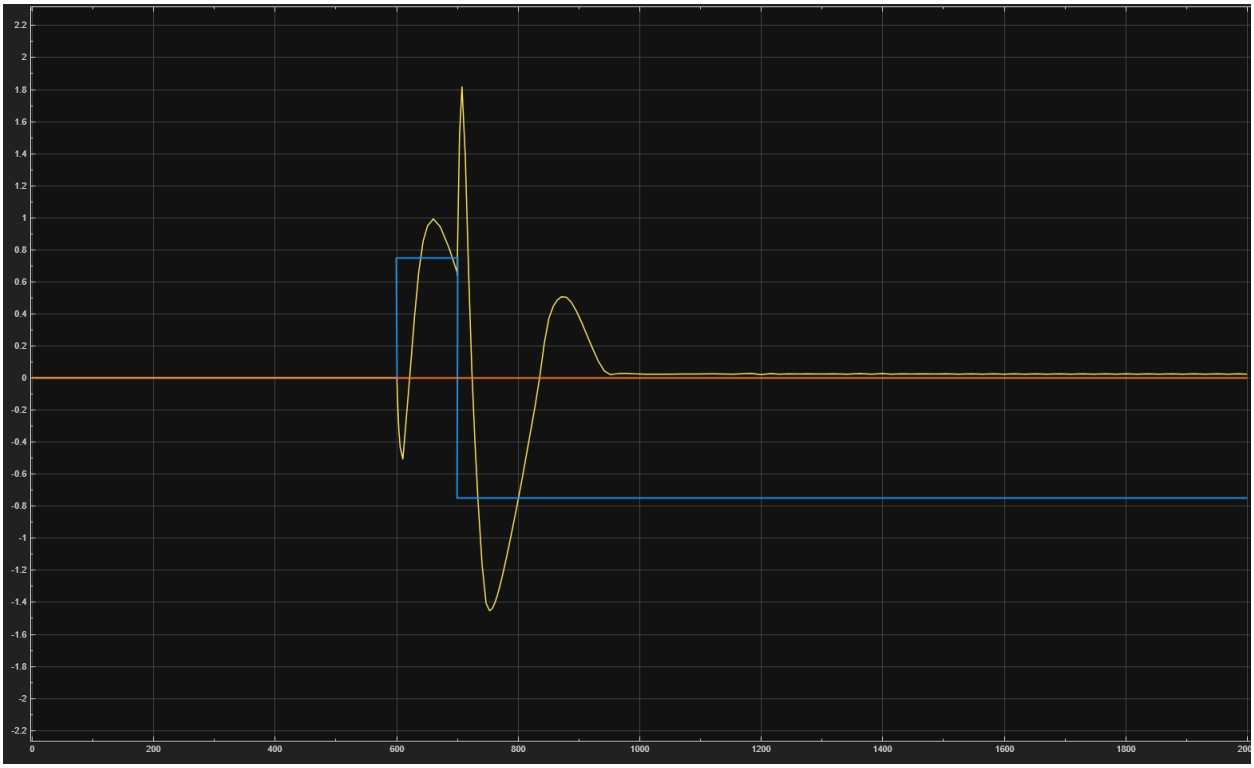
Na grafiku su prikazani ulazni signali fuzzy regulatora: greška (plava) i promena greške (žuta).

Uočava se da greška ima manju amplitudu i brzo se smiruje oko nule, dok promena greške pokazuje oštrije oscilacije u trenucima kada nastupi poremećaj. Ovakav odziv potvrđuje pravilno funkcionisanje fuzzy sistema – regulator brzo detektuje i reaguje na promene u sistemu, dok zadržava stabilnost i sprečava prekomerne oscilacije.



Žuta linija prikazuje signal pre integratora, koji sadrži nagle promene i brze oscilacije nastale kao direktan odziv fuzzy sistema. Plava linija prikazuje izlaz posle integratora, koji je znatno glađi i stabilniji.

Integrator uspešno filtrira visoke frekvencije i ublažava brze promene u upravljačkom signalu, što rezultuje stabilnijim i fizički realnijim odzivom sistema.



Na grafiku su prikazane tri krive:

- narandžasta – referentna vrednost
- plava – poremećaj
- žuta – izlaz sistema

Može se primetiti da izlaz uspešno prati referentni signal, čak i kada dođe do naglih poremećaja. Iako se javljaju prolazne oscilacije i kratkotrajni prenaponi, sistem se brzo stabilizuje i vraća u ravnotežu.

To pokazuje da fuzzy regulator efikasno suzbija dejstvo poremećaja i da sistem poseduje dobru otpornost na spoljašnje smetnje, uz kratak tranzijent i minimalnu statičku grešku.

Analiza odziva pokazuje da projektovani fuzzy regulator uspešno obezbeđuje stabilan i brz odziv sistema čak i u prisustvu poremećaja.

Greška se brzo smanjuje, tranzijent je kratak, a prenaponi su u prihvatljivim granicama.

Kombinacija Mamdani tipa fuzzy logike, Gausovih funkcija pripadnosti i integracione komponente je dovela do sistema koji reaguje dovoljno brzo, bez prekomernih oscilacija.

Ukupno, fuzzy regulator pokazuje visoku robusnost, stabilnost i prilagodljivost, što potvrđuje ispravnost projektovanog rešenja.